

# **Mini-Projet Machine Learning : Classification des Risques de Crise Cardiaque**

Omar Bouattour

Section : I1

Année Universitaire : 2024-2025

# Table des matières

|          |                                                |          |
|----------|------------------------------------------------|----------|
| <b>1</b> | <b>Introduction</b>                            | <b>3</b> |
| <b>2</b> | <b>Prétraitement des données</b>               | <b>3</b> |
| 2.1      | Chargement et exploration . . . . .            | 3        |
| 2.2      | Encodage des variables catégorielles . . . . . | 3        |
| 2.3      | Normalisation . . . . .                        | 3        |
| 2.4      | Division des données . . . . .                 | 3        |
| <b>3</b> | <b>Méthodes de Classification</b>              | <b>4</b> |
| 3.1      | K plus proches voisins (KNN) . . . . .         | 4        |
| 3.2      | Perceptron Multicouche (MLP) . . . . .         | 4        |
| 3.3      | Support Vector Machine (SVM) . . . . .         | 4        |
| <b>4</b> | <b>Évaluation des Performances</b>             | <b>5</b> |
| <b>5</b> | <b>Conclusion</b>                              | <b>5</b> |

# 1 Introduction

Dans le cadre de ce mini-projet d'apprentissage automatique, j'ai étudié la performance de plusieurs modèles de classification sur un jeu de données médicales (`heart.csv`) dans le but de prédire le risque de crise cardiaque. Ce projet m'a permis de mettre en pratique des techniques de prétraitement de données, d'entraînement de modèles, ainsi que d'évaluation des performances.

## 2 Prétraitement des données

### 2.1 Chargement et exploration

```
import pandas as pd
df = pd.read_csv("heart.csv")
print(df.head())
print(df.isnull().sum())
print(df['HeartDisease'].value_counts())
```

### 2.2 Encodage des variables catégorielles

```
from sklearn.preprocessing import LabelEncoder
cat_cols = df.select_dtypes(include='object').columns
df[cat_cols] = df[cat_cols].apply(LabelEncoder().fit_transform)
```

### 2.3 Normalisation

```
from sklearn.preprocessing import StandardScaler
X = df.drop('HeartDisease', axis=1)
y = df['HeartDisease']
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

### 2.4 Division des données

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(
    X_scaled, y, test_size=0.25, random_state=42
)
```

## 3 Méthodes de Classification

### 3.1 K plus proches voisins (KNN)

```
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import f1_score

f1_scores = []
for k in range(1, 21):
    knn = KNeighborsClassifier(n_neighbors=k)
    knn.fit(X_train, y_train)
    y_pred = knn.predict(X_test)
    f1_scores.append(f1_score(y_test, y_pred))
```

### 3.2 Perceptron Multicouche (MLP)

```
from sklearn.neural_network import MLPClassifier

mlp = MLPClassifier(hidden_layer_sizes=(100,), max_iter=1000, random_state=0)
mlp.fit(X_train, y_train)
y_pred_mlp = mlp.predict(X_test)
```

### 3.3 Support Vector Machine (SVM)

```
from sklearn.svm import SVC
from sklearn.model_selection import GridSearchCV

kernels = ['rbf', 'poly', 'sigmoid']
for kernel in kernels:
    grid = GridSearchCV(SVC(kernel=kernel), param_grid={
        'C': [0.1, 1, 10],
        'gamma': ['scale', 'auto']
    }, cv=5, scoring='f1')
    grid.fit(X_train, y_train)
    print(f"{kernel} - Best Params:", grid.best_params_)
    print(f"{kernel} - Best F1 Score:", grid.best_score_)
```

## 4 Évaluation des Performances

```
from sklearn.metrics import confusion_matrix, ConfusionMatrixDisplay

ConfusionMatrixDisplay(confusion_matrix(y_test, y_pred)).plot()
print("F1 Score:", f1_score(y_test, y_pred))
```

## 5 Conclusion

Ce projet m'a permis d'approfondir ma compréhension des techniques de classification en machine learning, du prétraitement à l'évaluation des performances. J'ai particulièrement constaté l'efficacité du modèle SVM avec noyau RBF dans ce contexte médical. J'ai aussi appris l'importance du réglage des hyperparamètres et du choix des métriques d'évaluation comme le F1 score pour avoir une vision plus fine de la performance du modèle.